

Rapport de Projet : Traitement de Données et Machine Learning

Prédiction de la Qualité du Vin Rouge

Membres de l'équipe :

Youssef Taghouti

Raphael Rideau

Matteo Levieil

5 juin 2026

Table des matières

1 Business Goal	3
1.1 Contexte	3
1.2 Quelle est l'utilité de notre dataset ?	3
1.3 Objectif	3
2 Team Management	4
2.1 Répartition des rôles	4
2.2 Workflow & Définition de la problématique	4
3 Data Visualization	5
3.1 Dataset Description et Répartition (Le Constat)	5
3.2 Corrélations Globales	5
3.3 Corrélations Globales	5
3.4 Interactions entre variables	6
4 Création de nouvelles variables (Handcrafted Features)	7
4.1 Validation et Pouvoir Discriminant des Caractéristiques	8
4.1.1 Analyse des Boîtes à Moustaches : L'Effet "Escalier"	8
4.1.2 Analyse des Écarts : Justification de la Division (Figure 5b)	8
5 Analyse par Régression Softmax	9
5.1 Choix du Modèle	9
5.2 Le Paradoxe de la Précision et l'Équilibrage des Classes	9

6 Conclusion	10
7 References	11

1 Business Goal

1.1 Contexte

Dans le cadre de ce projet, nous avons choisi d'analyser le dataset *Wine Quality (Red)*, regroupant des analyses physico-chimiques de 1349 variantes de vin rouge. Historiquement, l'évaluation de la qualité d'un vin repose exclusivement sur l'expertise humaine (les sommeliers), un processus subjectif, long et coûteux.

1.2 Quelle est l'utilité de notre dataset ?

Ce dataset [1] référence 11 caractéristiques chimiques objectives (taux d'alcool, pH, acidité volatile, sulfates, etc.) associées à une note de qualité (de 1 à 10) attribuée par des experts. Il nous permet de chercher des corrélations entre la composition moléculaire d'un vin et sa perception gustative. Nous pouvons ainsi déterminer si des éléments spécifiques, comme l'acidité volatile (responsable du goût de vinaigre), condamnent systématiquement une cuvée.

1.3 Objectif

Notre objectif principal est de construire un modèle prédictif capable d'estimer la qualité d'un vin avant son acquisition par un établissement de prestige, sur la seule base de sa fiche d'analyses chimiques en laboratoire. Dans le contexte d'un restaurant étoilé, le sommelier est confronté à un volume important de références à évaluer mais dispose d'un temps extrêmement limité, rendant une dégustation de chaque lot impossible.

Une réussite consisterait à fournir à ce professionnel un "système d'aide à la décision" fiable et rapide. Cela lui permettrait d'identifier mathématiquement et d'écarter les cuvées défectueuses ou non conformes aux standards de l'établissement, protégeant ainsi l'excellence et la réputation de la table étoilée. À l'inverse, ce modèle permettrait d'isoler objectivement les cuvées d'exception afin de justifier leur intégration dans une carte des vins Premium.

2 Team Management

2.1 Répartition des rôles

	Lundi	Mardi	Mercredi	Jeudi	Vendredi
Youssef Taghouti	Recherche de Dataset	Changement de dataset	Révision des handcrafted data	Création des diapos et début du rapport	Finalisation du rapport
		Analyse des notebooks	Modèle de régression linéaire		
		Début de création des handcrafted data			
Raphael Rideau	Recherche de Dataset	Changement de dataset	Révision des handcrafted data	Création des diapos et début du rapport	Finalisation du rapport
		Analyse des notebooks	Modèle de régression linéaire		
		Analyse des variables et de leur corrélations à la qualité du vin			
Matteo Leviell	Recherche de Dataset	Changement de dataset	Révision des handcrafted data	Création des diapos et début du rapport	Finalisation du rapport
		Analyse des notebooks	Analyse des handcrafted data finales		
		Début de création des handcrafted data			

Figure 1: Répartition des taches

2.2 Workflow & Définition de la problématique

Après une recherche de datasets pertinents, nous avons sélectionné le *Wine Quality Dataset* pour son équilibre entre lisibilité chimique et défi algorithmique. Nous avons défini la problématique suivante : *"Dans quelle mesure la chimie d'un vin dicte-t-elle sa qualité perçue, et comment modéliser mathématiquement l'excellence ?"*

3 Data Visualization

Notre analyse exploratoire des données et suit une logique en entonnoir : nous auditons d'abord la répartition de notre variable cible, nous identifions ensuite les descripteurs chimiques les plus influents, puis nous étudions les interactions entre ces variables pour nourrir notre modélisation.

3.1 Dataset Description et Répartition (Le Constat)

Le dataset contient 1349 lignes, sans aucune valeur manquante. La première étape a consisté à analyser la distribution de notre variable cible : la qualité.




Figure 2: Distribution de la qualité des vins étudiés [2]

Interprétation : Le graphique (Figure 2) révèle un déséquilibre massif. La très grande majorité de la production se situe dans la moyenne (notes 5 et 6), tandis que les vins excellents (7-8) ou très mauvais (3-4) sont rares. Pour optimiser l'apprentissage algorithmique et répondre à notre problématique métier (détecter les grands crus), nous avons décidé de regrouper ces notes en trois catégories d'analyse : **Médiocre**, **Standard**, et **Exceptionnel**.


3.2 Corrélations Globales

Pour comprendre l'effet individuel de chaque caractéristique chimique sur la note, nous avons généré une carte thermique des corrélations (*Heatmap*) [2] et une distribution des bons et mauvais vins [3].


3.3 Corrélations Globales

Pour identifier les variables discriminantes, nous avons croisé notre *Heatmap* [2] avec l'analyse des distributions de fréquences selon la qualité (Figure 4).

Interprétation : La *Heatmap* (Figure 4a) isole un "Trio d'Or" : l'Alcool (+0,48) et les Sulfates (+0,25) agissent comme des bonus, tandis que l'Acidité Volatile (-0,39) est un puissant malus.



(a) Matrice thermique



(b) Histogramme de la qualité du vin par variable

Figure 3: Graphiques permettant de désigner les variables utiles et inutiles

Pour les distributions nous avons pu voir 2 phénomènes

- **Variables homogènes (que nous avons écarté)** : Les composants dont les courbes se superposent entre bons et mauvais vins (sucre résiduel, pH, chlorures) ont été supprimés car ils n'apportent aucune information séparatrice.
- **Variables hétérogènes (conservées)** : Nous avons retenu les profils aux courbes nettement décalées (ex: le pic de l'alcool est à gauche pour les mauvais vins et à droite pour les excellents). Ce décalage géométrique confirme leur pouvoir discriminant pour le modèle.

3.4 Interactions entre variables

Les variables chimiques n'agissent pas de manière isolée. Pour découvrir comment elles interagissent, nous avons réalisé une Matrice Globale de Nuages de Points, croisant chaque variable avec toutes les autres.




Figure 4: Zoom sur les graphiques en 3 dimensions les plus explicatifs

Interprétation : En observant ces croisements, nous constatons que la séparation entre les vins *Exceptionnels* (points verts) et *Médiocres* (points rouges) dessine des formes géométriques. Par exemple, en croisant l'Alcool et l'Acidité Volatile, on observe une séparation en **diagonale**. En croisant l'Alcool et les Sulfates, les grands crus se regroupent dans un **quadrant** (en haut à droite). Ces observations visuelles sont la clé de notre ingénierie des données.

4 Création de nouvelles variables (Handcrafted Features)

Guidés par nos graphiques précédents, nous avons traduit les formes visuelles observées en équations mathématiques afin d'améliorer notre modèle de régression linéaire:

- **L'Indice Soustraction (Alcool - Acidité Volatile) :** L'analyse du premier graphique tridimensionnel montre une frontière linéaire et oblique entre les classes de qualité. Les points représentatifs des vins Exceptionnels (en vert) se concentrent dans la zone supérieure gauche (fort taux d'alcool, faible acidité volatile), tandis que les vins Médiocres (en rouge) migrent vers la zone inférieure droite. L'opérateur de soustraction permet de projeter ces coordonnées bidimensionnelles sur un axe unique de décision. Cette transformation n'améliore pas le modèle de manière extrême et ne permet pas de capturer des structures courbes, comme le feraient des interactions polynomiales de degré supérieur. En fournissant directement au modèle l'axe de cette diagonale sous forme d'une variable unique, on aligne l'un des axes de coordonnées de l'espace sur la frontière réelle de séparation des données.
- **L'Indice Soustraction (Sulfates - Acidité Volatile) :** Le troisième graphique tridimensionnel met en évidence une distribution spatiale similaire, comme pour le premier graphique. Bien que les données soient plus denses, on distingue un couloir diagonal ascendant où la concentration de vins de qualité supérieure s'intensifie à mesure que le ratio sulfates/acidité volatile augmente. Les anomalies qualitatives (points rouges) se situent majoritairement sous cette tendance, là où l'acidité volatile prend l'ascendant. Comme pour la handcrafted feature précédente, cela n'apporte pas de non linéarité et ne permet pas d'améliorer drastiquement le modèle mais permet tout de même de regrouper plusieurs variables sur un axe et donc d'avoir moins d'erreur au moment de l'analyse et de la prédiction du modèle.
- **L'Indice d'Excellence Ultime :** Le deuxième graphique tridimensionnel, qui croise l'Alcool et les Sulfates, met en évidence un phénomène de concentration non linéaire très net. Les points représentatifs des vins de qualité supérieure (en vert) ne se distribuent pas de manière diffuse, mais s'accumulent massivement dans le quadrant supérieur droit du graphique (coordonnées associant simultanément un fort taux d'alcool et une haute concentration en sulfates). À l'inverse, dès que l'une de ces deux variables fléchit, la densité de vins Exceptionnels chute drastiquement. Graphiquement, cette multiplication isole et cartographie précisément le quadrant supérieur droit identifié lors de l'analyse visuelle. En incluant une division par l'acide volatile, les vins médiocres se retrouvent écrasés près de 0, tandis que les vins exceptionnels obtiennent des scores extrêmement élevés.

1. Modèle Optimisé : Les 3 Handcrafted Features

Dans ce modèle, nous avons réduit la complexité à $n = 3$ variables géométriques conçues sur mesure. L'équation du score Z_k met en évidence l'Indice Soustraction, l'Indice Multiplication et l'Indice Ultime:

$$Z_k = \beta_{k,0} + \beta_{k,1}(\text{Alcool} - \text{Acidité Vol.}) + \beta_{k,2}(\text{Alcool} \times \text{Sulfates}) + \beta_{k,3} \left(\frac{\text{Alcool} \times \text{Sulfates}}{\text{Acidité Vol.} + \epsilon} \right) \quad (1)$$

Ces *Handcrafted Features* trient presque parfaitement les classes. Elles nous ont permis d'effectuer une sélection de caractéristiques en supprimant les colonnes d'origine de notre dataset.




Figure 5: Validation des variables *handcrafted* : distribution et pouvoir discriminant sur les classes de qualité.

4.1 Validation et Pouvoir Discriminant des Caractéristiques

4.1.1 Analyse des Boîtes à Moustaches : L'Effet "Escalier"

- **Indices Soustraction** : Les médianes progressent nettement de *Médiocre* à *Exceptionnel*. Le faible chevauchement des boîtes prouve que la variance inter-classes est maximisée, transformant une frontière diagonale complexe en un seuil numérique simple.
- **L'Indice d'Excellence Ultime** : Le score reste écrasé près de zéro pour les vins *Médiocres* et *Standards*, mais bondit pour les *Exceptionnels*. Cette asymétrie valide notre synergie multiplicative au numérateur, qui ne s'active que si le vin est excellent.

4.1.2 Analyse des Écarts : Justification de la Division (Figure 5b)

- **Profil des Vins Médiocres et Standards** : Ils présentent un fort déficit en alcool/sulfates mais une explosion de l'acidité volatile. Placer ce défaut au dénominateur écrase instantanément le score global de cette catégorie.
- **Profil des Vins Exceptionnels** : À l'inverse, l'acidité volatile s'effondre tandis que l'alcool et les sulfates culminent. Comme l'acidité volatile est minimale, le score n'est pas réduit par la division : le numérateur joue pleinement son rôle pour isoler cette catégorie des autres, ce qui accentue encore plus l'écart visuel et la nette séparation des Vins Exceptionnels sur nos graphiques.

Ces descripteurs ciblés éliminent le bruit de fond et permettent à la régression Softmax de lire indirectement les structures non linéaires indispensables à une prédiction fiable.

5 Analyse par Régression Softmax



5.1 Choix du Modèle

Étant donné que notre cible est constituée de 3 classes discrètes (*Médiocre*, *Standard*, *Exceptionnel*), une régression linéaire classique (visant une continuité infinie) était inadaptée. Nous avons opté pour une **Régression Softmax**. Le modèle calcule un score linéaire pondéré pour chaque classe, puis la fonction mathématique Softmax convertit ces scores en probabilités relatives.

5.2 Le Paradoxe de la Précision et l'Équilibrage des Classes

L'ajustement du modèle maintient une précision globale identique (82,5 %) mais transforme son utilité métier. Alors que la première version manquait la majorité des grands crus, le modèle final gagne considérablement en efficacité sur les *Vins Exceptionnels* en interceptant 44 échantillons sur 47 (Figure 6b).

Cette amélioration est directement visible sur les histogrammes (Figure 6c) : la distribution des *Vins Exceptionnels* (pics verts) se démarque et s'isole nettement des autres catégories, prouvant que nos variables *handcrafted* ciblent avec précision la signature chimique des grands vins.



(c) Importance mathématique des variables (Poids Softmax)

Figure 6: Évolution des performances du classifieur et impact des variables.

6 Conclusion

Ce projet démontre qu'il est possible de numériser partiellement le palais d'un sommelier en combinant l'ingénierie des données (*handcrafted features*) et le Machine Learning linéaire.

Un filtre de confiance pour l'établissement

Sur le plan applicatif, notre modèle se comporte comme un véritable **filtre de confiance**. En parvenant à isoler efficacement les potentiels grands crus, l'algorithme offre un double gain stratégique majeur pour un établissement de prestige :

- **Un temps précieux sauvé** : Le sommelier ou l'acheteur peut pré-trier instantanément des centaines de références à partir de simples fiches chimiques de laboratoire, focalisant son expertise humaine uniquement sur les lots jugés prometteurs.
- **Une réputation protégée** : En écartant en amont les anomalies et les cuvées non conformes, la table étoilée immunise sa carte des vins contre les mauvaises surprises gustatives.

La limite principale : La répartition des données

Malgré ces excellents résultats sur le rappel des classes critiques, le système se heurte à une contrainte structurelle intrinsèque liée à notre jeu de données : **la distribution asymétrique de la variable cible**.

- **Concentration sur la moyenne** : Le dataset d'apprentissage reste massivement centré sur la classe standard (note de 5 ou 6).
- **Manque de données sur les extrêmes** : La rareté statistique des *Vins Médiocres* et des *Vins Exceptionnels* bride la robustesse statistique de l'algorithme. Pour affiner sa précision discriminante, stabiliser sa frontière de décision et éviter certains faux positifs sur la catégorie centrale, l'algorithme a impérativement besoin d'être nourri avec un volume plus important d'exemples aux extrêmes (Grands Crus).

Perspectives

Pour briser les limites de la linéarité inhérentes à la régression Softmax, l'exploration de modèles non linéaires constituerait une suite logique. De plus, enrichir le profil chimique actuel par des descripteurs externes (cépage, climatologie de l'année, terroir) permettrait de concevoir un outil d'aide à la décision encore plus performant.

7 References

Lien vers notre github

<https://github.com/matteolevieil-blip/projet-traitement-de-donn-es/settings/access>

Références

[1] Notre dataset:

UCI Machine Learning, *Red Wine Quality Dataset (Cortez et al., 2009)*, Dépôt Kaggle.

<https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009/data>

[2] Notebook de la matrice de chaleur pour la corrélation:

A. Asiel, *Red Wine Quality EDA (Matrice de chaleur)*, Notebook Kaggle.

<https://www.kaggle.com/code/abubakerasiel/red-wine-quality-eda>

[3] Notebook de l'hitogramme entre bon et mauvais vins pour le choix de varaiables:

DarkmatterNet, *KNN Tutorial: Classification & Regression*, Notebook Kaggle.

<https://www.kaggle.com/code/darkmatternet/knn-tutorial-classification-regression>